

GeoNLA: 一种地理系统的神经网络分层架构类比 — 实验验证

Ma Rui

2026

摘要

地理系统呈现出典型的层状结构特征，其中物理因素（地形、气候、土壤）产生植被格局，进而塑造人类活动。2026) 假设地理圈层叠加过程与人工神经网络的层级计算之间存在结构同构性。本文提出GeoNLA的两层简化模型：(1) GeoNLA两阶段级联相匹配的合成数据；(2) 来自临夏盆地的真实栅格数据，数据源包括SRTM、WorldClim、SoilGrids、2、WorldCover、WorldPop和VIIRS。在合成数据上，与参数匹配的平坦MLP基线相比（652对678个参数），C

1 引言

地理现象源于多个圈层的相互作用——岩石圈、大气圈、土壤圈、生物圈和人类圈——每个圈层对下一个圈层施

Ma (2026)在GeoNLA（Geographic Neural Layered Architecture，地理神经网络分层架构）框架中形式化地表达了这一过程。例如，温度对植被的影响受到降水可利用性的调制，而物理景观对人类活动的影响则受到社会经济条件的调制。

本实验报告使用两层简化模型对GeoNLA假设进行受控验证。我们将GeoNLA与一个平坦MLP基线进行比较，以验证在可比模型容量下实现更好的性能。

我们在两条互补的数据路径上评估两个模型。合成数据的标签生成过程明确遵循GeoNLA两阶段级联，为架构验证提供基准。

2 研究区域与数据

2.1 合成数据

为创建受控测试环境，我们生成标签生成过程与GeoNLA两阶段级联相匹配的合成数据。合成数据模拟了类似真实世界的输入特征（12维）：

表 1: 按地理圈层组织的合成输入特征。

圈层	变量	维度
地形	海拔、坡度、起伏度	3
气候	温度、降水、干旱指数	3
土壤	有机质、黏粒含量、持水能力	3
植被	NDVI、NDVI振幅、草地比例	3

输出标签（6维）：

标签生成过程。标签通过三步过程生成，该过程精确对应GeoNLA同构的两阶段公式：

- 物理涌现：** $h_1 = \text{ReLU}(XW_1 + b_1)$ ，其中 $X \in \mathbb{R}^{N \times 12}$ ， $W_1 \in \mathbb{R}^{12 \times 32}$ 。
- 乘性时间调制：** $h_1(t) = h_1 \odot (1 + \Delta W \odot t)$ ，其中 $\Delta W \in \mathbb{R}^{32}$ 为可学习调制向量， t 为时间因子。
- 人地变换：** $y = \sigma(h_1(t)W_2 + b_2) \odot (1 + \text{社会经济调制})$ ，其中 $W_2 \in \mathbb{R}^{32 \times 6}$ ， σ 为sigmoid激活函数。

表 2: 合成输出标签。

变量	描述
耕地比例	农田面积占比
灌溉比例	灌溉面积占比
建设用地	建成区比例
人口密度	单位面积人口数
夜间灯光	辐射强度
道路密度	单位面积道路长度

这一数据生成过程确保GeoNLA的归纳偏置——具有乘性调制的分层级联——构成合成任务的”正确答案”。
数据集配置： 400个样本，80/20训练-验证划分（320个训练样本，80个验证样本）。

2.2 真实栅格数据（临夏盆地）

研究区域。 临夏盆地（35.3°N–35.8°N, 102.9°E–103.5°E）是甘肃省西北部的一个山间盆地。该区域地形复杂
数据来源。 所有栅格图层均重采样至统一的~1 km网格（GRID_STEP_DEG = 0.009° ≈ 0.8 km）：

表 3: 真实栅格实验的数据源与分辨率。

数据产品	变量	分辨率
SRTM DEM	海拔、派生坡度、起伏度	30 m → ~1 km
WorldClim v2	温度、降水、干旱指数	~1 km
SoilGrids v2.0	有机碳、黏粒含量、持水能力	250 m → ~1 km
Sentinel-2	NDVI均值、NDVI振幅、草地比例	10 m → ~1 km
ESA WorldCover	土地覆被分类	10 m → ~1 km
WorldPop	人口密度	~1 km
VIIRS夜间灯光	辐射强度	~500 m → ~1 km

特征提取。 从每个~1 km网格单元中，按照与合成数据相同的结构提取12个地理输入特征。6个输出标签由真实栅格数据集提供了现实的测试场景，其中真实的数据生成过程未知，标签是派生的（而非直接观测的）。

3 模型架构

3.1 GeoNLA（两层简化版）

GeoNLA模型通过三个计算阶段实现地理圈层叠加类比：

阶段1 — 物理层（地理圈层变换）：

$$h_1 = \text{ReLU}(\text{Linear}(X) + b_1), \quad h_1 \in \mathbb{R}^{32} \quad (1)$$

$$h_1 = \text{Dropout}(h_1, p = 0.2) \quad (2)$$

该层对应于从物理地理圈层（地形 → 气候 → 土壤 → 植被）到涌现潜在表示的变换。32维隐藏空间捕捉了具
阶段2 — 乘性时间调制：

$$h_1(t) = h_1 \odot (1 + \theta_{\text{time}} \odot f_{\text{time}}) \quad (3)$$

其中 $\theta_{\text{time}} \in \mathbb{R}^{32}$ 为可学习调制参数向量， f_{time} 为时间因子向量。这实现了GeoNLA理论中的 $W_k(t)$ 公式，捕捉季节和时序动态如何调制物理-人类耦合。

阶段3 — 人类层（人地关系涌现）：

$$y = \sigma(\text{Linear}(h_1(t)) + b_2), \quad y \in \mathbb{R}^6 \quad (4)$$

阶段4 — 社会经济调制：

$$y(t) = y \odot (1 + \theta_{\text{socio}} \odot f_{\text{socio}}) \quad (5)$$

其中 $\theta_{\text{socio}} \in \mathbb{R}^6$ 为可学习社会经济调制参数。

总可训练参数量： 652。

GeoNLA 两层架构示意图




图 1: 两层GeoNLA模型架构。物理层将12维地理输入变换为32维涌现表示，随后进行乘性时间调制，人类层将

3.2 FlatMLP基线

基线模型移除了所有GeoNLA假设特有的结构归纳偏置：

- **输入拼接：** 地理特征（12维）、时间因子和社会经济因子拼接为单一14维输入向量。
- **两层MLP：** $\text{Linear}(14 \rightarrow 32) + \text{ReLU} + \text{Dropout}(0.2) \rightarrow \text{Linear}(32 \rightarrow 6) + \text{Sigmoid}$
- **无圈层涌现，** 无乘性时间或社会经济调制。

总可训练参数量： 678。

参数量紧密匹配（652对678），确保任何性能差异反映的是架构归纳偏置而非模型容量。

4 实验设置

所有实验均在PyTorch (≥ 2.0) 中实现，配置如下：

表 4: 超参数配置。

超参数	值
优化器	Adam
学习率	1×10^{-3}
权重衰减	1×10^{-4}
学习率调度器	ReduceLROnPlateau (patience=15, factor=0.5)
损失函数	MSE
训练轮数	200
批次大小	32
随机种子	42

评估指标。 我们报告在验证集上计算的三个指标：

- **RMSE**（均方根误差）：度量整体预测量值误差。
- **MAE**（平均绝对误差）：度量平均绝对偏差。
- **R^2** （决定系数）：度量解释方差比例，报告所有输出维度的均值及每个单独输出维度的值。

可复现性。所有随机种子（Python、NumPy、PyTorch CPU/CUDA）均固定为42。代码库、数据生成脚本

5 结果

5.1 合成数据实验

表 5总结了合成数据上的整体验证性能。

表 5: 合成数据上的整体验证指标（400样本，80/20划分）。

模型	参数量	RMSE ↓	MAE ↓	R^2 （均值） ↑
GeoNLA	652	0.1140	0.0790	0.7918
FlatMLP	678	0.1221	0.0912	0.7621
改进	—	−6.6%	−13.3%	+0.030

GeoNLA在三个指标上均实现了显著提升。最显著的增益出现在MAE（−13.3%），表明具有乘性调制的分解表 6给出了逐维 R^2 分解，揭示了架构优势最为集中的位置。

表 6: 合成数据上的逐维 R^2 。

输出维度	GeoNLA	FlatMLP	Δ
耕地比例	0.710	0.651	+0.059
灌溉比例	0.822	0.746	+0.076
建设用地	0.711	0.700	+0.011
人口密度	0.891	0.880	+0.011
夜间灯光	0.829	0.838	−0.009
道路密度	0.787	0.757	+0.030

最大改进出现在**灌溉比例**（+0.076）和**耕地比例**（+0.059），这两者均受到物理地理级联（地形 → 气候 → 土壤 → 水资源可利用性）的强烈控制。这与GeoNLA假设一致：这些输出从分层地理变换中获益最

5.2 真实栅格数据实验

表 7展示了临夏盆地真实栅格数据集上的结果。

表 7: 真实栅格数据上的整体验证指标（临夏盆地，~1 km网格）。

模型	参数量	RMSE ↓	MAE ↓	R^2 （均值） ↑
GeoNLA	652	0.0342	0.0114	0.9120
FlatMLP	678	0.0351	0.0117	0.9107
改进	—	−2.7%	−3.1%	+0.001

改进方向一致，但与合成实验相比幅度较小。两个模型均达到较高的 R^2 值（ ≥ 0.91 ），反映了~1 km网格GeoNLA在**建设用地上**展现了最大优势（+0.013），该输出整合了多种物理地理约束（地形适宜性、水资源—具有更直接统计关系的变量——两个模型表现相当。道路密度显示完全相同的性能，表明架构差异对该特定输




图 2: GeoNLA与FlatMLP在合成数据上的训练和验证损失曲线。




图 3: 验证损失比较: GeoNLA vs. FlatMLP。




图 4: GeoNLA与FlatMLP的RMSE、MAE和 R^2 比较柱状图。




图 5: 合成数据上 GeoNLA 与 FlatMLP 的逐维 R^2 比较。

表 8: 真实栅格数据上的逐维 R^2 。

输出维度	GeoNLA	FlatMLP	Δ
建设用地	0.850	0.837	+0.013
人口密度	0.955	0.958	-0.003
夜间灯光	0.971	0.976	-0.005
道路密度	0.872	0.872	0.000




图 6: 真实栅格数据上所有输出维度的预测值 vs. 真实值散点图。

5.3 关键可视化

涌现层的t-SNE分析。32维涌现表示（阶段1输出）的t-SNE投影揭示，GeoNLA保留了地理相似性结构：来自相似地形-气候-土壤簇的网格单元在嵌入空间中位置接近，而来自不同地理环境的单元则良好分离。




图 7: 32维涌现层的t-SNE可视化。GeoNLA保留了地理相似性结构，来自相似地形-气候-土壤簇的单元位置接近。

权重热力图。学习得到的 W_1 （物理耦合， 12×32 ）和 W_2 （人地耦合， 32×6 ）权重矩阵揭示了可解释的耦合。时间调制效应。时间调制可视化展示了固定地理条件下12个月的预测人类活动值。乘性调制产生了逼真的季节模式——农业输出在生长季达到峰值，而建筑和人口相关输出呈现不同的时间模式——验证了GeoNLA框架中乘性时间调制的假设。

6 讨论

6.1 架构归纳偏置

实验结果一致支持核心GeoNLA假设：具有乘性调制的分层架构在建模地理人地关系方面优于参数匹配的平坦架构——数据生成过程精确对应GeoNLA公式——优势显著——RMSE降低6.6%，MAE降低13.3%。在真实栅格数据上，参数匹配设计（652对678个参数）至关重要：性能增益不能归因于模型容量的增加。相反，它反映了GeoNLA的架构归纳偏置——即地理信息通过结构化级联流动并伴随乘性圈层间耦合这一假设。




图 8: 学习得到的权重热力图。上方: W_1 (物理耦合, 12×32), 展示与四个地理圈层对应的连贯块状结构。下方: W_2 (人地耦合, 6×32), 揭示哪些涌现特征驱动人类活动输出。




图 9: 12个月的时间调制效应。固定地理条件下的预测人类活动值显示了由乘性时间耦合驱动的真实实现季节变化。

6.2 维度特异性分析

逐维 R^2 分析揭示了细致入微的图景。GeoNLA的优势在最直接受物理地理级联塑造的输出上最为显著——合成数据中的耕地比例和灌溉比例，以及真实数据中的建设用地。这些输出依赖于地形、气候、土壤和植被。相反，与输入特征具有更直接或更简单关系的输出（夜间灯光、道路密度）在两个模型之间表现相当。这表

6.3 可解释性

除预测性能外，GeoNLA架构还提供了可解释性优势。 W_1 权重矩阵揭示了物理地理因素如何耦合为涌现表示，涌现层的t-SNE可视化进一步证明，32维隐藏空间保留了有意义的地理相似性——这一特性自然地架构设计。时间调制分析为乘性耦合机制提供了直接证据。通过在固定地理条件下可视化12个月的预测，我们观察到

6.4 局限性

需要承认以下几点局限性：

1. **两层简化**。完整的GeoNLA理论假设六个地理圈层，但当前实验验证仅使用两层（物理 → 人类）。扩展到完整的六层架构可能揭示额外优势，但也引入了优化和数据需求方面的挑战。
2. **标签派生噪声**。在真实栅格实验中，输出标签由遥感分类和人口栅格产品派生，而非来自直接统计调查。
3. **空间自相关**。两个模型均未显式考虑数据中的空间自相关。当前实现将每个网格单元独立处理，忽略了地
4. **样本量**。合成数据集（400样本）和真实栅格数据集（来自单一盆地~1 km网格采样）在深度学习标准下
5. **因果关系 vs. 相关关系**。虽然GeoNLA架构编码了地理圈层的因果排序，但实验验证展示的是相关性改进

7 结论

本实验报告对GeoNLA框架的核心假设进行了受控验证：地理圈层叠加过程与神经网络层级计算之间存在结构。使用两层简化模型，我们证明GeoNLA在合成数据（RMSE -6.6%，MAE -13.3%）和临夏盆地真实栅格数据（RMSE -2.7%，MAE -3.1%）上均优于参数匹配的平坦MLP基线。两条数据路径上的改进方向一致，改进幅度反映了。除预测性能外，GeoNLA架构提供了可解释的权重结构（ W_1 、 W_2 ），在其涌现表示中保留了地理相似性，——这些特性共同支持了地理圈层叠加与神经网络层级计算之间的理论类比。

未来工作将聚焦于三个方向：(1) 将两层模型扩展到对应所有地理圈层的完整六层GeoNLA架构；(2) 整合卷神经网络同构性在不同环境设置下的泛化性。

参考文献

- [1] Ma, R. (2026). Geo-NLA: Neural Network Layered Architecture as an Analogy for Geographic Systems. Zenodo. <https://doi.org/10.5281/zenodo.21350728>
- [2] NASA JPL (2013). Shuttle Radar Topography Mission (SRTM) Global. NASA EOSDIS Land Processes DAAC. <https://doi.org/10.5067/MEPEWDXG2HSK>
- [3] Fick, S. E. & Hijmans, R. J. (2017). WorldClim 2: new 1-km spatial resolution climate surfaces for global land areas. International Journal of Climatology, 37(12), 4376–4390. <https://doi.org/10.1002/joc.5086>
- [4] Poggio, L., de Sousa, L. M., Batjes, N. H., et al. (2021). SoilGrids 2.0: producing soil information for soil quantities with quantified spatial uncertainty. SOIL, 7(2), 999–1020. <https://doi.org/10.5194/soil-2021-46>

- [5] ESA WorldCover Consortium (2021). ESA WorldCover 10 m 2020 v1.0. Zenodo.
<https://doi.org/10.5281/zenodo.5571936>
- [6] WorldPop (www.worldpop.org).
- [7] Elvidge, C. D., et al. (2021). VIIRS DNB annual composites. Earth Observation Group, Colorado School of Mines.